
## 데이터마이닝 과제 2016170864 산업경영공학부 조동혁



```
In [1]: import pandas as pd
            from sklearn import datasets
           load_df=datasets.load_breast_cancer()
           data=pd.DataFrame(Inad.df.data)
           feature=pd.DataFrame(load_df.feature_names)
           data.columns=feature[0]
           data.co/umms=leatureg(load_df.target)
target=pd.DataFrame(load_df.target)
target.columns=['target']
df=pd.concat([data,target], axis=1)
print(df.shape)
           df.head()
           (569, 31)
Out [1]:
                                            mean mean 
area smoothness
                                                                  mean mean compactness concavity
                                                                                                       mean 
symmetry
                                                                                                                                   worst worst texture perimeter
               mean mean mean radius texture perimeter
                                                                                             concave
                                                                                               points
                                                                                                                    dimension
            0 17.99
                         10.38
                                    122.80 1001.0
                                                         0.11840
                                                                        0.27760
                                                                                     0.3001
                                                                                              0.14710
                                                                                                           0.2419
                                                                                                                       0.07871
                                                                                                                                      17.33
                                                                                                                                                184.60 2019.0
                                                                                                                                                                       0.1622
                                                                                              0.07017
                                                                                                                       0.05667
                         17.77
                                                         0.08474
                                                                        0.07864
                                           1326.0
                                                                                     0.0869
                                                                                                           0.1812
                                                                                                                                      23.41
                                                                                                                                                158.80
                                                                                                                                                                       0.1238
                19.69 21.25
                                   130.00 1203.0
                                                         0.10960
                                                                        0.15990
                                                                                     0.1974 0.12790
                                                                                                           0.2069
                                                                                                                       0.05999
                                                                                                                                     25.53
                                                                                                                                                152.50 1709.0
                                                                                                                                                                      0.1444
                11.42
                       20.38
                                    77.58 386.1
                                                         0.14250
                                                                        0.28390
                                                                                     0.2414 0.10520
                                                                                                           0.2597
                                                                                                                       0.09744
                                                                                                                                     26.50
                                                                                                                                                 98.87
                                                                                                                                                        567.7
                                                                                                                                                                       0.2098
            4 20.29 14.34 135.10 1297.0
                                                         0.10030
                                                                        0.13280
                                                                                     0.1980 0.10430
                                                                                                           0.1809
                                                                                                                      0.05883
                                                                                                                                    16.67
                                                                                                                                                152.20 1575.0
                                                                                                                                                                      0.1374
           5 rows × 31 columns
```

데이터는 Breast Cancer 데이터를 사용했습니다. 문제 정의는: 어떤 설명변수가 가장 Breast Cancer 에 영향을 많이 주는지 확인을 하는 것입니다.



key 값들을 확인해준결과, 데이터의 양 및 정보가 너무 많아서, PCA 로 차원축소를 하기로 결정 했습니다.

```
In [6]: # Data Normalizing (Mean Centering)


from sklearn.preprocessing import StandardScaler
X_ = StandardScaler().fit_transform(X)

In [17]: # PCA 수행 - 주성분 3개
pca = PCA(n_components=3)
pc = pca.fit_transform(X_)

In [18]: # 카테고리정보 (음성 양성)
pc_y = np.c_[pc_y]
df = pd.DataFrame(pc_y,columns=['PC1','PC2','PC3','diagnosis'])

In [19]: #Plotting
fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')
ax.scatter(df['PC1'], df['PC2'], df['PC3'], c=df['diagnosis'], s=20)

Out[19]: <mpl_toolkits.mplot3d.art3d.Path3DCollection at 0x2b0033287c0>
```




우선, 변수들을 표준화 작업을 mean centering 용법으로 해주었습니다. 그 후에는 주성분을 3 개를 기준으로 계산을 해주었으며, 3 차원 공간에 plotting을 해주었습니다.

PCA 결과: 주성분 3 개가 합쳐서 대략 70%의 데이터를 설명해줄수 있었습니다.


```
In [1]: import pandas as pd
          import numpy as np
from sklearn import datasets
          from matplotlib import pyplot as plt
In [4]: cancer = datasets.load_breast_cancer()
data=pd.DataFrame(cancer.data) ; data
          feature=pd.DataFrame(cancer.feature_names) ; feature
          data.columns=feature[0]
         target=pd.DataFrame(cancer.target)
target.columns=['target']
          df=pd.concat([data,target], axis=1)
Out [4]:
                                                                                    mean
concave
points
                                                                                              mean 
symmetry
          0 17.99
                       10.38
                                122.80 1001.0
                                                    0.11840
                                                                 0.27760
                                                                             0.3001
                                                                                     0.14710
                                                                                                 0.2419
                                                                                                           0.07871
                                                                                                                         17.33
                                                                                                                                   184.60 2019.0
                                                                                                                                                       0.1622
              20.57
                      17.77
                                                   0.08474
                                                                 0.07864
                                                                                                           0.05667
                                                                                                                                   158.80 1956.0
                                                                                                                                                       0.1238
                                132.90 1326.0
                                                                             0.0869
                                                                                     0.07017
                                                                                                 0.1812
                                                                                                                         23.41
          2 19.69
                     21.25
                               130.00 1203.0
                                                   0.10960
                                                                 0.15990
                                                                             0.1974 0.12790
                                                                                                 0.2069
                                                                                                            0.05999
                                                                                                                         25.53
                                                                                                                                   152.50 1709.0
                                                                                                                                                       0.1444
               11.42
                      20.38
                                77.58 386.1
                                                   0.14250
                                                                 0.28390
                                                                             0.2414 0.10520
                                                                                                 0.2597
                                                                                                            0.09744
                                                                                                                         26.50
                                                                                                                                    98.87
                                                                                                                                          567.7
                                                                                                                                                       0.2098
                                                   0.10030
                                                                                                           0.05883
                                                                                                                                  152.20 1575.0
          4 20.29 14.34
                               135.10 1297.0
                                                                 0.13280
                                                                             0.1980 0.10430
                                                                                                 0.1809
                                                                                                                         16.67
                                                                                                                                                       0.1374
          5 rows × 31 columns
```

Breast Cancer 데이터의 군집화를 보기위해서 Clustering 작업을 진행 해주었습니다.

위 데이터들을 2 차원 공간에 mean texture, perimeter, area 를 기준으로 가시화 시켜주었습니다.



X= mean radius Y= mean texture Z= mean area



3 차원 공간상에서도 가시화를 시켜주었습니다. 사이즈는 10, 투명도는 1 로 설정해주었습니다. 2 차원, 3 차원 공간상에 가시화된 plot 들을 보니, 데이터가 군집화가 전혀 안되어 있는 모습을 볼수 있었습니다. K-means를 사용해서 군집수를 찾고 다시 plotting을 진행 해주었습니다.

```
In [9]: from sklearn, cluster import KMeans
          ks = range(1,10)
inertias = []
          for k in ks:
   model = KMeans(n_clusters=k)
   model,fit(df_f)
               inertias,append(model,inertia_)
          plt.figure(figsize=(4, 4))
          plt.plot(ks, inertias, '-o')
plt.xlabel('number of clusters, k')
plt.ylabel('inertia')
          plt,xticks(ks)
          C:\Users\Administrator\anaconda3\lib\site-packages\sklearn\cluster\_kmeans.py:881: User\arning: KMeans is known to have a memory
          leak on Windows with MKL, when there are less chunks than available threads. You can avoid it by setting the environment variable OMP_NUM_THREADS=3.
            warnings,warn(
             2.5
             2.0
         erie
15
             1.0
             0.5
             0.0
```

## k 개수를 늘렸더니, k=3 일때가 elbow point 인 것을 알수가 있었습니다.

```
In [23]: clust_model = KMeans(n_clusters = 3
                                                          , n_init=10
                                                          , max_iter=50
                                                           , random_state = 42)
                  clust_model,fit(df_f)
                  centers = clust_model,cluster_centers_
                 pred = clust_model,predict(df_f)
print(pd,DataFrame(centers))
                  print(pred[:10])
                 0 12,475172 18,490117 80,576410 488,859207 0,094915 0,090775 1 18,528512 21,579091 122,283471 1074,812397 0,100261 0,141827
                  2 23,401579 22,762105 156,147368 1729,421053 0,104154 0,171922
                                                                         8
                                                                                            9
                 0 0.061506 0.032939 0.177987 0.063573 ... 24,599044 91,227110
1 0.161977 0.092081 0.191677 0.060620 ... 28,774711 149,064463
                                                                                                                                   91.227110
                  2 0,239016 0,134858 0,185884 0,059145 ... 30,295263 203,073684

        23
        24
        25
        26
        27
        28
        29

        0
        609,272261
        0,13029
        0,222372
        0,216940
        0,090475
        0,282925
        0,083394


        1
        1546,471074
        0,139227
        0,346118
        0,431358
        0,182433
        0,315463
        0,086227

        2
        2765,842105
        0,141511
        0,389416
        0,505995
        0,227526
        0,289633
        0,081874

                                   30
                 0 0,827506
                  1 0.016529
                  2 0,000000
                  [3 rows x 31 columns]
[1 1 1 0 1 0 1 0 0 0]
```

Cluster 개수 =3 으로 K-means 모델링을 진행 해주었습니다. 또한, 각 군집의 Center-value 를 가져왔습니다.

결과를 다시 plotting 을 해주었습니다. 각 검은 점들은 각 cluster 들의 중심값을 나타내주고 있는 모습입니다.




mean radius

```
In [26]:

# 3对世皇星 시작화하기
fig = plt,figure(figsize=(8, 8))
ax = fig.add_subplot(111, projection='3d')
x = clust_df

ax.scatter( X.iloc[:,0] , X.iloc[:,1] , X.iloc[:,2] , c = X.clust , s = 10 , cmap = "rainbow" , alpha = 1 )

ax.scatter(centers[:,0],centers[:,1],centers[:,2] ,c='black', s=200)
ax.set_xlabel(data.columns[0] )
ax.set_ylabel(data.columns[1] )
ax.set_zlabel(data.columns[2] )
plt.show()
```



변수가 4개지만, k=3 이기 때문에, 변수 4개를 두번에 걸쳐서 3차원에서 plotting 했습니다.

데이터를 가지고 이제 modeling을 진행 해주었습니다.

```
In [11]: from sklearn import datasets
               import pandas as pd
    In [12]: cancer = datasets,load_breast_cancer()
   Out[12]: {'data': array([[1,799e+01, 1,038e+01, 1,228e+02, ..., 2,654e-01, 4,601e-01,
                         1,189e-01],
[2,057e-01, 1,777e+01, 1,329e+02, ..., 1,860e-01, 2,750e-01, 8,902e-02],
[1,969e+01, 2,125e+01, 1,300e+02, ..., 2,430e-01, 3,613e-01,
                          8,758e-02],
                         [1,660e+01, 2,808e+01, 1,083e+02, ..., 1,418e-01, 2,218e-01,
                         7,820e-02],
[2,060e+01, 2,933e+01, 1,401e+02, ..., 2,650e-01, 4,087e-01, 1,240e-01],
                         [7,760e+00, 2,
7,039e-02]])
                                        2,454e+01, 4,792e+01, ..., 0,000e+00, 2,871e-01,
 In [13]: print(cancer,keys())
             dict_keys(['data', 'target', 'frame', 'target_names', 'DESCR', 'feature_names', 'filename'])
 In [16]:
cancer['target']
                                     0, 1, 0, 1, 1,
1, 1, 0, 1, 1,
1, 0, 1, 1, 0,
1, 1, 0, 1, 0,
1, 0, 1, 0, 0,
                                                        0, 1,
1, 1,
1, 1,
1, 0,
1, 1,
1, 1,
                                                                   1, 1, 0, 0, 1,
1, 1, 1, 0, 1,
1, 1, 1, 1, 1,
                                                                                          1, 0, 1, 1,
1, 1, 1, 1,
1, 1, 1, 1,
                                 0.
                                                                                      0,
1,
1,
                                                               0,
1,
                                 ο,
                                                               1, 0, 0,
```

Dataset 을 다시 와서 load 를 해주었습니다. Dictionary 형태로 표현을 해주었습니다.

```
In [17]: X = cancer.data[:, :2]
          y = cancer,target
In [18]: import matplotlib.pyplot as plt
plt.scatter(X[:, 0], X[:, 1], c=y, cmap=plt.cm,Set1, edgecolor='k')
Out [18]: <matplotlib,collections,PathCollection at 0x263f6645340>
             35
            30
            25
            20
            15
            10
In [19]: from sklearn,neighbors import KNeighborsClassifier
           from sklearn,model_selection import train_test_split, cross_val_score
           x_train, x_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=30)
           KNN_MODEL = KNeighborsClassifier()
           KNN_MODEL.fit(x_train, y_train)
prediction = KNN_MODEL.predict(x_test)
                                          : {0:,3f}",format(KNN_MODEL,score(x_train, y_train)))
: {0:,3f}",format((prediction==y_test),mean()))
           print ("Training error
print ("Testing error
                                           : {0:,3f}",format(cross_val_score(KNN_MODEL, X, y, cv=10),mean()))
           print("cross_val_score
           Training error
Testing error
                                  : 0,910
: 0,901
           cross_val_score
                                   : 0,873
```

x 변수를 가져와야하지만, 전부 다 가져왔더니 실행이 너무 느려서, 두개의 변수를 가지고 와서 설정을 해주었습니다.

또한, 예측성능을 진행 해주었습니다. Test size 는 30%로 잡아주었고, training test 는 70%로 설정 해주었습니다. Training error 는 91%, testing error 는 90%가 나왔습니다.

```
In [20]: train_sec = []

test_sec = []

test_sec = []

for n in range(1,15):

NNLMODEL = Note(sphores)

NNLMODEL = Note(sphores)

NNLMODEL = Note(sphores)

prediction = NNLMODEL (rest)

train_sec_sepend(NNLMODEL, sore(x(.rein), y_train))

test_sec_sepend((prediction==y_test), mean())

In [21]:

import_numpy as no

pit.figuref(spize-(1,9))

pit.plot(range(1, 15), train_sec_, label="Training Dataset")

pit.plot(range(1, 15), test_sec_, label="Test Dataset")

pit.ylabel("express")

pit.ylabel("express")
```


마지막으로, Training accuracy, test accuracy 를  $1\sim15$  로 주면서 모델링을 해주었습니다. Test data 는  $11\sim14$  에서 높은 모습을 보여주고 있습니다. K 값을  $11\sim14$  로 잡고 모델링을 해주면 될거 같다는 결론을 지었습니다.

```
In [5]: from sklearn,datasets import load_breast_cancer
           from sklearn,model_selection import train_test_split
 In [6]: cancer=load_breast_cancer()
 In [7]: X_train, X_test, y_train, y_test = train_test_split(cancer.data, cancer.target, test_size=0.2, random_state=24)
 In [8]: from sklearn, tree import DecisionTreeClassifier
           DT_MODEL= DecisionTreeClassifier(random_state=0)
DT_MODEL.fit(X_train, y_train)
           predict ion=DT_MODEL.predict(X_test)
 In [9]:
           from sklearn,metrics import classification_report, confusion_matrix
CM=confusion_matrix(y_test, prediction)
CM_report=classification_report(y_test, prediction)
print('-'*15, 'Confusion Matrix','-'*15)
print(CM)
           print('-'*15, 'Confusion Matrix2','-'*15)
           -mport pandas as pu
CM_rename=pd,DataFrame(CM),rename(index={0:'실제값(0)',1:'실제값(1)',2:'실제값(2)'},columns={0:'예측값(0)',1:'예측값(1)',2:'예측값
print(CM_rename)
           4
                           -- Confusion Matrix --
           [[36 5]
[ 3 70]]
                           -- Confusion Matrix2 -
                  실제값(0)
실제값(1)
                                      70
                             3
In [10]:
           print('-'*20, '성능평가','-'*20)
print(CM_report)
                              ---- 성능평가 ----
                           precision recall f1-score support
                                           0,88
0,96
                                                        0,90
0,95
                                 0.92
                ассигасу
                                                                      114
                                         0,9∠
0,93
                                 0.93
               macro avg
                                                         0.92
                                                                      114
           weighted avg
                                                         0,93
                                0,93
```

의사결정나무 algorithm 을 DecisionTreeClassifier 를 사용해주었습니다. Test size 는 8:2 비율로 해주었습니다. Confusion matrix 및 prediction 을 진행 해주었습니다.


CM\_report 를 통해서 성능평가를 해주었습니다.

```
In [12]:
    import matplotlib.pyplot as plt
    from sklearn.tree import plot_tree
    plt.figure(figsize=(15,10))
    plot_tree(DT_MODEL,feature_names=cancer.feature_names, class_names=cancer.target_names, filled=True, fontsize=9)
    plt.show()
```



의사결정나무를 가시화 해주었습니다. 455 개의 샘플을 가지고 해주었습니다.

```
In [14]:
         prediction_DEP3=DT_MODEL_DEP3,predict(X_test)
         CM_DEP3=confusion_matrix(y_test, prediction_DEP3)
CM_report_DEP3=classification_report(y_test, prediction_DEP3)
         print('-'*15, 'Confusion Matrix','-'*15)
         print(CM_DEP3)
print('-'*20, '성능평가','-'*20)
print(CM_report_DEP3)
         plt.figure(figsize=(15,10))
         plot_tree(DT_MODEL_DEP3, feature_names=cancer.feature_names, class_names=cancer.target_names, filled=True, fontsize=9)
         plt,show()
                    ---- Confusion Matrix -----
         [[35 6]
[ 3 70]]
                            -- 성능평가 ---
                                    recall f1-score support
                       precision
                                                 0,89
0,94
                            0,92
0,92
                                       0,85
0,96
                    0
                                                 0,92
                                                            114
             ассигасу
                            0.92
                                       0.91
                                                 0.91
                                                            114
            macro avg
         weighted avg
                            0,92
                                       0,92
                                                 0,92
```



가지치기 진행할때는, Depth 설정은 3 으로 해주었습니다. 결과를 confusion matrix 로 보니까, 아까보다 한 개 더 정답을 맞추어 주었습니다.

```
In [22]: # 변수 중요도
                                                                      for name, value in zip(cancer.feature_names , DT_MODEL_DEP3.feature_importances_):
    print('{0} : {1:,3f}',format(name, value))
                                                                        # 변수 중요도 기시회
                                                                        import seaborn as sns
                                                                      \verb|sns|, \verb|barp|| ot (x=DT\_MODEL\_DEP3, feature\_importances\_|, y=cancer, feature\_names)|
                                                                   mean radios : 0,000
mean texture : 0,010
mean perimeter : 0,000
mean area : 0,000
mean smoothness : 0,000
                                                                     mean compactness : 0,000
mean concavity : 0,000
                                                                mean concavity: 0,000
mean concave points: 0,000
mean symmetry: 0,000
mean fractal dimension: 0,000
radius error: 0,000
texture error: 0,000
area error: 0,000
smoothness error: 0,000
concavity error: 0,000
cymmetry error: 0,000
symmetry error: 0,000
concavit dimension error: 0,000
worst radius: 0,000
worst radius: 0,000
                                                                   worst radius: 0,000
worst texture: 0,000
worst perimeter: 0,000
worst area: 0,794
                                                                   worst area: 0,794
worst smoothness: 0,000
worst compactness: 0,000
worst concavity: 0,000
worst concave points: 0,166
worst symmetry: 0,000
worst fractal dimension: 0,000
Out [22]: <AxesSubplot:>
                                                                            mean radius
mean texture
mean perimeter
mean serimeter
mean smoothess
mean compactness
mean concavity
mean concavity
mean fractal dimension
mean fractal dimension
                                                                             mean fractal affirmation
facilities and the facilities afficies af
                                                                                                                                                                                                                                  0.1
                                                                                                                                                                                                                                                                        0.2
                                                                                                                                                                                                                                                                                                             0.3 0.4 0.5
                                                                                                                                                                                                                                                                                                                                                                                                                                  0.6
                                                                                                                                                                                                                                                                                                                                                                                                                                                                            0.7
```

마지막으로 변수의 중요도를 결정 해주었습니다. 결과로 봤을 때, worst area 가 가장 중요한 변수였으며, 그 다음으로는 worst concave pointsm texture error, mean texture 순서대로 높은 중요도를 보여주고 있습니다.